

# Integración de Cambios Geométricos y Metamodelos en Simulaciones FEM

**Alumno:** Jorge Zorrilla Prieto (Universidad Carlos III Madrid).

**Tutor del Proyecto:** Rafael Vázquez Hernández (Universidad Santiago de Compostela).

**Contacto de la empresa:** Gabriel Curtosi (SEAT).

## Objetivos

En la industria automovilística, los requisitos de seguridad exigidos a los fabricantes de automóviles por parte de las autoridades aseguradoras se incrementan cada año. Para poder cumplir con dichos requisitos, los fabricantes deben realizar las llamadas Pruebas de Choque (*crash tests*). Estas pruebas de choque deben contemplar diversos escenarios en los que la seguridad de los integrantes del vehículo puede ponerse en riesgo. Uno de los tests con mayor impacto en la certificación de seguridad de un vehículo es la variación y deformación del B-Pilar II en los choques laterales de los automóviles, el cual se considera tiene una gran repercusión en la seguridad de los ocupantes.

Sin embargo, debido a diversas variables durante el proceso de fabricación y ensamblaje de los automóviles, puede haber cierta incertidumbre y variabilidad en los resultados de dichos tests.

Debido a que las pruebas tienen un alto impacto económico para el fabricante, no se puede realizar un test diferente con cada una de las diversas combinaciones de estas variables para todos los escenarios. Es por esto que se debe acudir al uso de simulaciones de software realistas para reproducir de una manera fidedigna los resultados generados por las pruebas reales en los diversos escenarios y configuraciones del modelo de automóvil.

Aunque esta metodología es mucho más factible desde un punto de vista práctico y supone un gran ahorro, el hardware actual aún necesita grandes tiempos de computación para poder realizar estas simulaciones, pudiendo llevar hasta 6 horas para ciertas simulaciones (por ejemplo para un choque lateral en el vehículo) con el grado de precisión requerido. Debido a esto, las simulaciones actuales se tienen que hacer para un número limitado de variables, conllevando a un número limitado de resultados que pueden no representar todo el espectro de resultados posibles ante una situación de choque del vehículo.

Es por esto que desde SEAT surge la herramienta interna AQUA, la cual a partir de un número de resultados obtenidos de simulaciones, hace uso de las técnicas de *Machine Learning* para la generación predictiva de resultados de un abanico mucho mayor de combinaciones que puedan abarcar un espectro mucho más fiel y realista.

Una de las limitaciones que tiene esta herramienta es que sigue siendo necesario un número relativamente grande de simulaciones (con su consiguiente coste computacional) de entrada para poder obtener los resultados exigidos. La otra limitación es el no poder

incluir variaciones geométricas para alimentar los modelos de entrenamiento, estando limitados a unas mallas de elementos finitos con un número de nodos fijo, que no pueden representar las diversas variaciones que pudieran aparecer durante el proceso de diseño, fabricación y ensamblaje de una pieza.

El objetivo de este Trabajo de Fin de Máster (TFM) es el desarrollo de estrategias para incluir la variación geométrica en los modelos y la inclusión de metodologías para reducir el número de simulaciones de partida necesarias para el entrenamiento de los modelos de *Machine Learning*.

## Integración de variables geométricas

Planteamiento e implementación de diversas estrategias para poder incluir variaciones geométricas de diseño en la malla de elementos finitos. Estas variaciones podrían incluir desde cambios sencillos en la geometría, cambio de características de los agujeros de la malla o inclusión de nuevos agujeros a cambios más complejos en una posible etapa más avanzada del proyecto.

En cuanto a las diversas estrategias que se contemplan serían la *Voxelization* para hacer uso de mallas volumétricas en las que el impacto en los cambios de geometría sea menor, o el uso de *Convolutional Neural Networks* (CNN) o *Graph Neural Networks* (GNN) para poder introducir las propiedades de la malla o sus atributos (CNN) o directamente su composición usando los *nodes* o los *edges* (GNN).

## Reducción de coste computacional

Se plantea el uso de *Physics Informed Neural Networks* para poder introducir así modelos físicos como parámetros dentro de las computaciones de Machine Learning. De esta manera se espera poder alcanzar resultados de predicción similares con un menor valor de variables de entrada.

## Plan de trabajo

Tras una primera reunión de planteamiento de objetivos, se plantea el siguiente plan de trabajo para el desarrollo del TFM.

- 1) Utilización del programa comercial de simulación dinámica de choque *Pam-Crash* para la generación de los resultados de partida usando diversas mallas sencillas con cambios mínimos (cambio/integración de agujeros, cambios sencillos en la malla...).
- 2) Utilización de las herramientas mencionadas (CNN, *voxelization*, GNN) para la predicción de resultados de choque a partir de las diversas mallas de entrada y sus variaciones.
- 3) Hacer uso de herramientas estadísticas y de Aprendizaje No Supervisado para obtener conclusiones a partir de los resultados, observar las variaciones con más influencia en estos así como las combinaciones de ellas que conlleven unos mejores resultados finales.

- 4) Integración de Leyes Físicas en los modelos de entrenamiento de AQUA usando *Physics Informed Neural Networks* para poder así analizar si de esta manera se pueden obtener resultados similares con un menor número de parámetros de entrada.